

UniSENAI PR – Londrina

Curso de Engenharia de Software

Disciplina: Ciência de Dados

Professor: Paulo Cesar Dias Lima

Período: 5º | Ano/Semestre: 2026/1

ATIVIDADE PRÁTICA AVALIATIVA

Visualização de Dados • Engenharia de Features • Redução de Dimensionalidade

Aluno(a): Lucas Andreassa Justino

RA: 00933766

Turma: Engenharia de Software - 5º Período

Data de entrega: 10 de Junho de 2026

Link Colab:

https://colab.research.google.com/drive/1i8Tm69hu0tHu1d9dK5nY_jMbNVBgRnsy?usp=sharing

1. Apresentação

Esta atividade prática tem por finalidade consolidar conhecimentos fundamentais de Ciência de Dados aplicada ao desenvolvimento de soluções computacionais, com ênfase em análise exploratória de dados, pré-processamento, engenharia de atributos e redução de dimensionalidade.

Ao longo da atividade, o(a) estudante deverá aplicar técnicas amplamente utilizadas em projetos de análise de dados e aprendizado de máquina, desenvolvendo não apenas a implementação computacional em Python, mas também a interpretação crítica dos resultados obtidos.

2. Objetivos de aprendizagem

- Realizar análise exploratória de dados por meio de visualizações estatísticas adequadas.
- Identificar padrões, distribuições, correlações e possíveis outliers.
- Aplicar procedimentos de tratamento e transformação de dados.
- Desenvolver estratégias de engenharia de features.
- Compreender e aplicar técnicas de redução de dimensionalidade, especialmente PCA e t-SNE.
- Produzir interpretações técnicas consistentes a partir de experimentos computacionais.

3. Competências desenvolvidas

- Análise crítica de dados
- Raciocínio estatístico aplicado
- Implementação de bibliotecas de Ciência de Dados em Python
- Comunicação técnica de resultados
- Tomada de decisão baseada em evidências
- Organização e documentação de experimentos computacionais

4. Orientações gerais

A atividade deverá ser desenvolvida em Python e preferencialmente no Google Colab. O código entregue deve estar funcional, organizado e comentado. Todas as respostas interpretativas devem ser escritas em linguagem técnica clara e objetiva. Sempre que solicitado, apresente gráficos, métricas e justificativas analíticas. Não serão aceitas respostas compostas apenas por código sem interpretação dos resultados.

5. Bibliotecas e bases de dados sugeridas

- **Bibliotecas recomendadas:** pandas, numpy, matplotlib, seaborn, scikit-learn, plotly
- **Bases de dados de referência:** Tips dataset (Seaborn), Wine dataset (Scikit-learn), Digits dataset (Scikit-learn), House Prices (Kaggle)





6. Exercício 1 — Visualização de Dados e Análise Exploratória

Tema: Exploração visual do conjunto de dados tips.

Objetivo: Realizar uma análise exploratória inicial, identificando padrões relevantes em variáveis numéricas e categóricas.

Análise do Exercício 1:

1. **Distribuição e Assimetria das Gorjetas:** A análise do histograma indica que a distribuição das gorjetas (variável `tip`) é marcadamente assimétrica à direita (assimetria positiva). O maior pico de densidade e concentração encontra-se na faixa compreendida entre \$2.00 e \$3.50. Conforme os valores aumentam, a frequência diminui de maneira exponencial, embora a cauda se estenda até o limite superior próximo a \$10.00, impulsionada por pagamentos esporádicos de alta magnitude.
2. **Comportamento dos Outliers:** A inspeção visual do Boxplot aplicado à variável `total_bill` evidencia a presença de múltiplos pontos isolados situados além do limite superior. Do ponto de vista do negócio, estes registros não correspondem a erros de inserção de dados, mas sim a perfis de consumo atípicos (contas de valor elevado feitas por grandes grupos), configurando outliers legítimos que demandam atenção na modelagem preditiva.
3. **Faturamento, Sazonalidade e Correlação Linear:** O gráfico de barras por dia demonstra que o maior fluxo de clientes e de faturamento concentra-se no fim de semana (sábado e domingo). Além disso, o gráfico de dispersão (*scatter plot*) confirma visualmente uma tendência de correlação linear positiva moderada a alta (~ 0.68) entre o valor da conta e a gorjeta paga, indicando que o volume de consumo é o principal fator preditor para a gratificação deixada pelo cliente.



7. Exercício 2 — Pré-processamento e Engenharia de Features

Tema: Tratamento e transformação de dados em um problema de previsão de preços de imóveis.

Objetivo: Aplicar técnicas de limpeza, imputação, escalonamento, codificação e criação de novas variáveis explicativas.

Análise do Exercício 2:

1. **Tratamento de Dados Ausentes:** A estratégia de eliminação cega de linhas através do método de exclusão (dropna) reduziria desnecessariamente o volume amostral da base de dados, sacrificando 5% de instâncias úteis. Em contrapartida, a imputação baseada na mediana mostrou-se a decisão técnica mais robusta para as colunas numéricas (area, bathrooms, year_built), pois impede que valores extremos distorçam o preenchimento, preservando a integridade estatística da amostra.
2. **Impacto das Novas Features:** A engenharia de atributos (*feature engineering*) desempenhou um papel catalisador na performance preditiva do modelo *Random Forest*. A criação de atributos estruturados baseados no conhecimento de domínio, tais como idade_imovel, razao_area_quarto e a flag categórica recém_construido, permitiu que o modelo capturasse relações não-lineares mais complexas. Isso refletiu-se de forma empírica numa melhoria consistente do Erro Absoluto Médio (MAE) e numa expansão no coeficiente de determinação (R^2).
3. **Mitigação de Vazamento de Dados (Data Leakage):** O risco principal ao criar atributos derivados é a inclusão involuntária de informações da variável alvo (price). Para garantir o isolamento metodológico e evitar vazamentos, todas as transformações foram baseadas única e exclusivamente nas variáveis predictoras independentes (idade calculada pelo ano, rácio de dimensões físicas), impossibilitando o acesso direto à resposta final durante o treino.



8. Exercício 3 — Redução de Dimensionalidade

Tema: Aplicação de PCA e t-SNE em bases clássicas de classificação.

Objetivo: Compreender como técnicas de redução de dimensionalidade podem auxiliar na visualização, interpretação e simplificação de dados multivariados.

Análise do Exercício 3:

1. **Diferenças Conceituais (PCA vs. t-SNE):** O PCA é um algoritmo linear, determinístico, focado na maximização e preservação da variância global através de componentes principais ortogonais. É altamente indicado para mitigação de multicolinearidade e pré-processamento rápido. Já o t-SNE é uma abordagem estocástica, não-linear e probabilística, focada na preservação rigorosa de vizinhanças e distâncias locais em espaços de baixa dimensão, sendo ideal para a exploração visual de agrupamentos (*clusters*) complexos.
2. **Comportamento no Dataset Wine (PCA):** A projeção do PCA atingiu uma retenção de variância expressiva apenas com os dois primeiros componentes principais. A dispersão gerada foi capaz de segmentar visualmente de forma satisfatória os três tipos de cultura de vinho, demonstrando o poder de separação dos eixos de maior variância num contexto linear.
3. **Comportamento no Dataset Digits (t-SNE):** O t-SNE provou a sua eficácia na formação de agrupamentos de imagens manuscritas, mas revelou forte sensibilidade ao hiperparâmetro perplexity. Ao utilizar uma perplexidade muito baixa (e.g., 8), as classes de dígitos fragmentaram-se em subgrupos dispersos. Por outro lado, ao ajustar para uma perplexidade mais alta e adequada (e.g., 45), o algoritmo convergiu em blocos homogêneos e globais, revelando perfeitamente as estruturas e fronteiras das dez classes numéricas.



9. Entregáveis

- Arquivos dos código-fontes do projeto do aluno do Notebook COLAB (.py e .ipynb).
- Relatório em PDF contendo as análises, explicações, gráficos, respostas interpretativas, conclusões, link do projeto do COLAB compartilhado.
- Evidências visuais dos experimentos realizados.
- Conclusão e documento PDF Gerado e entregue via AVA integrando os três exercícios.

10. Critérios de avaliação

- Organização do código (Clareza, legibilidade e boas práticas) - 1,0
- Correção técnica (Uso adequado de bibliotecas e métodos) - 1,0
- Visualização de dados (Qualidade e pertinência dos gráficos) - 2,0
- Análise interpretativa (Capacidade de extrair e explicar insights) - 2,0
- Engenharia de features (Coerência das transformações e comparação) - 2,0
- Redução de dimensionalidade (Aplicação e interpretação de PCA/t-SNE) - 2,0
- **Total sugerido: 10,0 pontos.**

11. Conclusão geral do aluno

Conclusão geral:

A execução desta Atividade Prática Avaliativa (APS2) propiciou um entendimento prático e consolidado acerca do ciclo fundamental da Ciência de Dados. Ficou evidente que a aplicação direta de algoritmos sem uma etapa prévia e rigorosa de análise visual e saneamento de dados gera frequentemente modelos com viés e de baixa generalização.

A exploração inicial permitiu mapear distribuições assimétricas e comportamentos atípicos no dataset financeiro de gorjetas. Paralelamente, a experiência com os dados imobiliários sublinhou que a inteligência de negócio colocada na engenharia de features costuma ser muito mais

relevante para o ganho de métricas (R^2 , MAE) do que apenas o ajuste fino do algoritmo.

Por fim, a experimentação analítica entre PCA e t-SNE clarificou os casos de uso para a redução de dimensionalidade: atestando que técnicas lineares protegem a representação global dos dados visando eficiência computacional, enquanto os algoritmos não-lineares são os recursos definitivos para garantir a interpretabilidade visual na procura por *clusters* latentes em sistemas multidimensionais de alta complexidade.

12. Observação final

Esta Atividade Prática Avaliativa foi estruturada com base nas aulas ministradas, bem como nos conceitos, conteúdos, exemplos, materiais e referências disponibilizados na disciplina de Ciência de Dados, os quais fundamentam as competências e habilidades a serem consideradas e aplicadas pelo aluno nesta atividade.